



Universidade Federal
de Campina Grande

Processamento Adaptativo de Sinais

Introdução às Redes Neurais MLP

Edson P. da Silva

Programa de Pós-Graduação em Engenharia Elétrica (PPgEE).

Unidade Acadêmica de Engenharia Elétrica (UAEE)

Universidade Federal de Campina Grande (UFCG)

Sumário



Universidade Federal
de Campina Grande

1. Regressão e classificação.
2. Perceptron.
3. Perceptron de múltiplas camadas.
4. Algoritmo *Backpropagation*.

Regressão e Classificação

- **Regressão:** o objetivo de uma regressão é prever o valor de uma ou mais variáveis d dado o valor de um vetor $\mathbf{x} \in \mathbb{R}^D$. Comumente dispomos de um conjunto de N observações $\{\mathbf{x}_k\}$, em que $k = 1, \dots, N$, com os correspondentes valores alvo $\{d_k\}$ e desejamos prever o valor de d para um novo vetor de entrada $\mathbf{x}$.


Regressão e Classificação

- **Regressão:** o objetivo de uma regressão é prever o valor de uma ou mais variáveis d dado o valor de um vetor $\mathbf{x} \in \mathbb{R}^D$. Comumente dispomos de um conjunto de N observações $\{\mathbf{x}_k\}$, em que $k = 1, \dots, N$, com os correspondentes valores alvo $\{d_k\}$ e desejamos prever o valor de d para um novo vetor de entrada $\mathbf{x}$.
- Como solução para o problema de regressão, definimos uma função (ou modelo) $y(\mathbf{x}, \mathbf{w})$ cujos valores de saída constituem previsões de valores de d , em que $\mathbf{w}$ representa o vetor de parâmetros do modelo.

Regressão e Classificação

- **Regressão:** o objetivo de uma regressão é prever o valor de uma ou mais variáveis d dado o valor de um vetor $\mathbf{x} \in \mathbb{R}^D$. Comumente dispomos de um conjunto de N observações $\{\mathbf{x}_k\}$, em que $k = 1, \dots, N$, com os correspondentes valores alvo $\{d_k\}$ e desejamos prever o valor de d para um novo vetor de entrada $\mathbf{x}$.
- Como solução para o problema de regressão, definimos uma função (ou modelo) $y(\mathbf{x}, \mathbf{w})$ cujos valores de saída constituem previsões de valores de d , em que $\mathbf{w}$ representa o vetor de parâmetros do modelo.
- **Exemplo** (regressão linear):

$$\begin{aligned} y(\mathbf{x}, \mathbf{w}) &= w_0 + w_1 x_1 + \dots + w_D x_D \\ &= w_0 + \sum_{j=1}^D w_j x_j \end{aligned}$$




Regressão e Classificação




Universidade Federal
de Campina Grande

- **Classificação:** o problema de classificação consiste em tentar prever a classe c associada a um vetor de entrada $\mathbf{x} \in \mathbb{R}^D$. Comumente, dispomos de um conjunto de N observações $\{\mathbf{x}_k\}$, em que $k = 1, \dots, N$, com as correspondentes classes alvo $\{c_k\}$, e desejamos prever a classe c para um novo vetor de entrada $\mathbf{x}$.



Regressão e Classificação

- **Classificação:** o problema de classificação consiste em tentar prever a classe c associada a um vetor de entrada $\mathbf{x} \in \mathbb{R}^D$. Comumente, dispomos de um conjunto de N observações $\{\mathbf{x}_k\}$, em que $k = 1, \dots, N$, com as correspondentes classes alvo $\{c_k\}$, e desejamos prever a classe c para um novo vetor de entrada $\mathbf{x}$.
- Como solução para o problema de classificação, definimos uma função (ou modelo) $y(\mathbf{x}, \mathbf{w})$, cujos valores de saída constituem previsões de probabilidade para cada classe c . A classe prevista para uma nova entrada $\mathbf{x}$ é aquela com a maior probabilidade estimada.



Regressão e Classificação

- **Exemplo** (regressão logística): considere o problema de classificação binária, em que a função $y(\mathbf{x}, \mathbf{w})$ mapeia a entrada para um valor entre 0 e 1, interpretado como a probabilidade da entrada $\mathbf{x}$ pertencer à classe classe 1, ou formalmente

$$y(\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}$$

onde $\mathbf{x} \in \mathbb{R}^D$ é o vetor de entrada, $\mathbf{w} \in \mathbb{R}^D$ é o vetor de parâmetros do modelo e

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

é a função sigmoide, que mapeia $\mathbf{w}^T \mathbf{x}$ para um número no intervalo entre 0 e 1.

Para uma nova entrada $\mathbf{x}$, se $y(\mathbf{x}, \mathbf{w}) \geq 0.5$, a previsão será a classe 1; caso contrário, será a classe 0.

Perceptron



Universidade Federal
de Campina Grande

Perceptron




Universidade Federal
de Campina Grande

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.


Perceptron

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.



Perceptron


- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.



$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$$

Perceptron

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.




$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$$

$$\mathbf{x} = [+1, x_1, \dots, x_D]^T$$

Perceptron

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.




$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$$

$$\mathbf{x} = [+1, x_1, \dots, x_D]^T$$

$$\mathbf{w} = [w_0, \dots, w_D]^T$$

Perceptron

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.



$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$$


$$\mathbf{x} = [+1, x_1, \dots, x_D]^T$$

$$\mathbf{w} = [w_0, \dots, w_D]^T$$

$f(.)$ é uma função não-linear com saturação brusca.

Perceptron

- O perceptron é um modelo de rede neural artificial que foi criado por Frank Rosenblatt em 1957.
- Ele é considerado um dos algoritmos mais simples de aprendizado supervisionado e é a base de redes neurais mais complexas.



$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^T \mathbf{x})$$

$$\mathbf{x} = [+1, x_1, \dots, x_D]^T$$

$$\mathbf{w} = [w_0, \dots, w_D]^T$$

$f(\cdot)$ é uma função não-linear com saturação brusca.

- O parâmetro w_0 permite adicionar um deslocamento (*offset*) arbitrário nos dados e é comumente denominado de parâmetro de *bias*.

Perceptron



Universidade Federal
de Campina Grande

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} \quad \frac{\partial J}{\partial \mathbf{w}} = -2e \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} \quad \frac{\partial J}{\partial \mathbf{w}} = -2e \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Seja $a = \mathbf{w}^T \mathbf{x}$, temos que:

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} \quad \frac{\partial J}{\partial \mathbf{w}} = -2e \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Seja $a = \mathbf{w}^T \mathbf{x}$, temos que:

$$\frac{\partial f(a)}{\partial \mathbf{w}} = \frac{\partial f(a)}{\partial a} \frac{\partial a}{\partial \mathbf{w}}$$

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} \quad \frac{\partial J}{\partial \mathbf{w}} = -2e \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Seja $a = \mathbf{w}^T \mathbf{x}$, temos que:

$$\frac{\partial f(a)}{\partial \mathbf{w}} = \frac{\partial f(a)}{\partial a} \frac{\partial a}{\partial \mathbf{w}} \implies \frac{\partial f(a)}{\partial \mathbf{w}} = \frac{df(a)}{da} \mathbf{x}$$

Perceptron

- Cálculo de gradientes considerando a função de custo erro quadrático instantâneo:

$$J = \|d - y\|^2 = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$$

$$\frac{\partial J}{\partial \mathbf{w}} = -2d \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} + 2f(\mathbf{w}^T \mathbf{x}) \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}} \quad \frac{\partial J}{\partial \mathbf{w}} = -2e \frac{\partial f(\mathbf{w}^T \mathbf{x})}{\partial \mathbf{w}}$$

Seja $a = \mathbf{w}^T \mathbf{x}$, temos que:

$$\frac{\partial f(a)}{\partial \mathbf{w}} = \frac{\partial f(a)}{\partial a} \frac{\partial a}{\partial \mathbf{w}} \implies \frac{\partial f(a)}{\partial \mathbf{w}} = \frac{df(a)}{da} \mathbf{x} \quad \frac{\partial J}{\partial \mathbf{w}} = -2ef'(a)\mathbf{x}$$


Perceptron

Funções de ativação:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Função sigmóide $\sigma(x)$:

$$\sigma'(x) = \sigma(x)[1 - \sigma(x)]$$




Perceptron

Funções de ativação:

Função tangente hiperbólica $\tanh(x)$:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$\tanh'(x) = 1 - \tanh^2(x)$$



Perceptron




Universidade Federal
de Campina Grande

Funções de ativação:

$$\text{ReLU}(x) = \max(0, x)$$

Função unidade linear retificada $\text{ReLU}(x)$:

$$\text{ReLU}'(x) = \begin{cases} 1 & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$



Perceptron



Universidade Federal
de Campina Grande

Observações:

Perceptron

Observações:

- No caso geral, a função de custo $J = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$ define uma superfície multidimensional complexa, com diversos mínimos locais. Desse modo, algoritmos de otimização via gradiente estão sujeitos à convergência para mínimos locais.


Perceptron

Observações:

- No caso geral, a função de custo $J = d^2 - 2df(\mathbf{w}^T \mathbf{x}) + f(\mathbf{w}^T \mathbf{x})^2$ define uma superfície multidimensional complexa, com diversos mínimos locais. Desse modo, algoritmos de otimização via gradiente estão sujeitos à convergência para mínimos locais.
- O gradiente $\frac{\partial J}{\partial \mathbf{w}} = -2ef'(z)\mathbf{x}$ depende de $f'(z)$ que, por sua vez, pode assumir valores muito pequenos a depender dos valores assumidos por z . Dessa forma, mesmo se o erro calculado na saída do modelo for alto, ainda é possível que o ajuste dos pesos do modelo estacione pois $\frac{\partial J}{\partial \mathbf{w}} \approx 0$, se $f'(z) \approx 0$.


Perceptron Multicamadas

- Uma Rede Neural Perceptron Multicamadas (*Multilayer Perceptron* - MLP) é um tipo de rede neural artificial que consiste em, no mínimo, três camadas de neurônios: uma camada de entrada (*input layer*), uma ou mais camadas ocultas (*hidden layer*) e uma camada de saída (*output layer*).



Perceptron Multicamadas

- Uma Rede Neural Perceptron Multicamadas (*Multilayer Perceptron* - MLP) é um tipo de rede neural artificial que consiste em, no mínimo, três camadas de neurônios: uma camada de entrada (*input layer*), uma ou mais camadas ocultas (*hidden layer*) e uma camada de saída (*output layer*).



- A MLP é uma das arquiteturas mais comuns em aprendizado de máquina e é usada em problemas de classificação e regressão.



Universidade Federal
de Campina Grande

Perceptron Multicamadas

- Uma rede MLP consegue aprender padrões não-lineares presentes nos dados de treinamento devido às funções de ativação não-lineares presentes em suas camadas ocultas.

Perceptron Multicamadas

- Uma rede MLP consegue aprender padrões não-lineares presentes nos dados de treinamento devido às funções de ativação não-lineares presentes em suas camadas ocultas.
- **Capacidade de aproximação universal:** dado um número suficiente de neurônios e camadas, uma MLP pode aproximar qualquer função contínua, tornando-a poderosa para tarefas de mapeamento complexas.

Perceptron Multicamadas

- Matrizes de pesos:

$$\mathbf{W}^{(i)} = \begin{bmatrix} w_{11}^{(i)} & w_{12}^{(i)} & \cdots & w_{1n_i}^{(i)} \\ w_{21}^{(i)} & w_{22}^{(i)} & \cdots & w_{2n_i}^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n_{i+1}1}^{(i)} & w_{n_{i+1}2}^{(i)} & \cdots & w_{n_{i+1}n_i}^{(i)} \end{bmatrix} \in \mathbb{R}^{n_{i+1} \times n_i}$$

Perceptron Multicamadas

- Matrizes de pesos:

$$\mathbf{W}^{(i)} = \begin{bmatrix} w_{11}^{(i)} & w_{12}^{(i)} & \cdots & w_{1n_i}^{(i)} \\ w_{21}^{(i)} & w_{22}^{(i)} & \cdots & w_{2n_i}^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n_{i+1}1}^{(i)} & w_{n_{i+1}2}^{(i)} & \cdots & w_{n_{i+1}n_i}^{(i)} \end{bmatrix} \in \mathbb{R}^{n_{i+1} \times n_i}$$

- O número de linhas da matriz $\mathbf{W}^{(i)}$ representa o número de neurônios da camada $i + 1$.
- O número de colunas da matriz $\mathbf{W}^{(i)}$ representa o número de neurônios da camada i .
- Cada elemento $w_{jk}^{(i)}$ na matriz $\mathbf{W}^{(i)}$ representa o peso da conexão entre o k -ésimo neurônio na camada i e o j -ésimo neurônio na camada $i + 1$.

Perceptron Multicamadas

- Na propagação direta, a matriz $\mathbf{W}^{(i)}$ é usada para calcular a entrada ponderada $\mathbf{a}^{(i+1)}$ na camada $i + 1$ através do produto matricial:

$$\mathbf{a}^{(i+1)} = \mathbf{W}^{(i)} \mathbf{z}^{(i)} + \mathbf{b}^{(i+1)}$$

Perceptron Multicamadas

- Na propagação direta, a matriz $\mathbf{W}^{(i)}$ é usada para calcular a entrada ponderada $\mathbf{a}^{(i+1)}$ na camada $i + 1$ através do produto matricial:

$$\mathbf{a}^{(i+1)} = \mathbf{W}^{(i)} \mathbf{z}^{(i)} + \mathbf{b}^{(i+1)}$$

- Para cada camada i , as *ativações* são calculadas aplicando-se a função $f(.)$ às entradas ponderadas $\mathbf{a}^{(i)}$:

$$\mathbf{z}^{(i)} = f(\mathbf{a}^{(i)})$$

Perceptron Multicamadas

- Na propagação direta, a matriz $\mathbf{W}^{(i)}$ é usada para calcular a entrada ponderada $\mathbf{a}^{(i+1)}$ na camada $i + 1$ através do produto matricial:

$$\mathbf{a}^{(i+1)} = \mathbf{W}^{(i)} \mathbf{z}^{(i)} + \mathbf{b}^{(i+1)}$$

- Para cada camada i , as *ativações* são calculadas aplicando-se a função $f(\cdot)$ às entradas ponderadas $\mathbf{a}^{(i)}$:

$$\mathbf{z}^{(i)} = f(\mathbf{a}^{(i)})$$

- Para a camada de saída, a saída da rede é calculada aplicando-se a função $g(\cdot)$ às entradas ponderadas $\mathbf{z}^{(i)}$:

$$\mathbf{y} = g(\mathbf{a}^{(i)})$$

Perceptron Multicamadas

- A matriz Jacobiana de uma função de ativação f é dada por:

$$\frac{\partial f(\mathbf{a}^{(i)})}{\partial \mathbf{a}^{(i)}} = \text{diag}(f'(\mathbf{a}^{(n)})) = \begin{bmatrix} f'(a_1^{(i)}) & 0 & \dots & 0 \\ 0 & f'(a_2^{(i)}) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & f'(a_n^{(i)}) \end{bmatrix}$$

Perceptron Multicamadas

- A matriz Jacobiana de uma função de ativação f é dada por:

$$\frac{\partial f(\mathbf{a}^{(i)})}{\partial \mathbf{a}^{(i)}} = \text{diag}(f'(\mathbf{a}^{(n)})) = \begin{bmatrix} f'(a_1^{(i)}) & 0 & \dots & 0 \\ 0 & f'(a_2^{(i)}) & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & f'(a_n^{(i)}) \end{bmatrix}$$

- Regra da cadeia com matrizes: no cálculo matricial multivariável, se temos uma função escalar J , e variáveis vetoriais $\mathbf{u}$ e $\mathbf{v}$ relacionadas por uma transformação linear onde a matriz $\mathbf{A}$ é constante em relação a $\mathbf{v}$:


$$\mathbf{u} = \mathbf{A}\mathbf{v}$$

Temos que as derivadas do escalar J em relação ao vetor $\mathbf{v}$ e à matriz $\mathbf{A}$ serão dadas por:

$$\frac{\partial J}{\partial \mathbf{v}} = \mathbf{A}^T \frac{\partial J}{\partial \mathbf{u}} \quad \frac{\partial J}{\partial \mathbf{A}} = \frac{\partial J}{\partial \mathbf{u}} \mathbf{v}^T$$


Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:



Perceptron Multicamadas


- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:



$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:




$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:




$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:



$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$


$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:



$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$


$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Perceptron Multicamadas

- Considere inicialmente o caso simples em que a MLP possui apenas uma camada oculta:



$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J(\mathbf{y}) = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} \|\mathbf{e}\|^2$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \frac{\partial J}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}} = (\mathbf{y} - \mathbf{d}) \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \frac{\partial J}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}} = (\mathbf{y} - \mathbf{d}) \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(2)}}$$

$\mathbf{x} \odot \mathbf{y} \implies$ produto de Hadamard.
(produto elemento-a-elemento)

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \frac{\partial J}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}} = (\mathbf{y} - \mathbf{d}) \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) (\mathbf{z}^{(2)})^T$$

$\mathbf{x} \odot \mathbf{y} \implies$ produto de Hadamard.
(produto elemento-a-elemento)

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \frac{\partial J}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}} = (\mathbf{y} - \mathbf{d}) \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) (\mathbf{z}^{(2)})^T$$

$\mathbf{x} \odot \mathbf{y} \implies$ produto de Hadamard.
(produto elemento-a-elemento)

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \frac{\partial J}{\partial \mathbf{y}} \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}} = (\mathbf{y} - \mathbf{d}) \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(2)}}$$

$$= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) (\mathbf{z}^{(2)})^T$$

$\mathbf{x} \odot \mathbf{y} \implies$ produto de Hadamard.
(produto elemento-a-elemento)

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} (\mathbf{z}^{(2)})^T$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)}\mathbf{z}^{(2)})}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)}\mathbf{z}^{(2)})}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \frac{\partial \mathbf{z}^{(2)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)}\mathbf{z}^{(2)})}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \frac{\partial \mathbf{z}^{(2)}}{\partial \mathbf{W}^{(1)}}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(1)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial (\mathbf{W}^{(1)}\mathbf{x})}{\partial \mathbf{W}^{(1)}} \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(1)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial (\mathbf{W}^{(1)}\mathbf{x})}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \mathbf{x}^T \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(1)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial (\mathbf{W}^{(1)}\mathbf{x})}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \mathbf{x}^T \end{aligned}$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação à matriz de pesos $\mathbf{W}^{(1)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(1)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial (\mathbf{W}^{(1)}\mathbf{x})}{\partial \mathbf{W}^{(1)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \mathbf{x}^T \end{aligned}$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(1)} \mathbf{x}^T$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação às matrizes de pesos:

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação às matrizes de pesos:

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação às matrizes de pesos:

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação às matrizes de pesos:

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} (\mathbf{z}^{(2)})^T$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação às matrizes de pesos:

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} (\mathbf{z}^{(2)})^T$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(1)} \mathbf{x}^T$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(3)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(3)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(3)}} &= (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(3)}} \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(3)}} &= (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(3)}} &= (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \end{aligned}$$

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(3)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(3)}} &= (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(3)}} \\ &= \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \end{aligned}$$

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\frac{\partial J}{\partial \mathbf{b}^{(3)}} = \delta^{(2)}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)}\mathbf{z}^{(2)})}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)}\mathbf{z}^{(2)})}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \frac{\partial \mathbf{z}^{(2)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{y} - \mathbf{d})^T \frac{\partial \mathbf{y}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \mathbf{e} \odot g'(\mathbf{a}^{(3)}) \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial \mathbf{a}^{(3)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(2)} \frac{\partial (\mathbf{W}^{(2)} \mathbf{z}^{(2)})}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \frac{\partial \mathbf{z}^{(2)}}{\partial \mathbf{b}^{(2)}}$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(2)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{b}^{(2)}}{\partial \mathbf{b}^{(2)}} \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(2)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{b}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \end{aligned}$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(2)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{b}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \end{aligned}$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

Algoritmo Backpropagation

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$\mathbf{y} = g(\mathbf{W}^{(2)} f(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}) + \mathbf{b}^{(3)})$$

Função de custo J erro quadrático instantâneo:

$$J = \frac{1}{2} \|\mathbf{e}\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2} (\mathbf{y} - \mathbf{d})^T (\mathbf{y} - \mathbf{d})$$

- Gradiente de J com relação ao vetor de bias $\mathbf{b}^{(2)}$:

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{b}^{(2)}} &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{a}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \frac{\partial \mathbf{b}^{(2)}}{\partial \mathbf{b}^{(2)}} \\ &= (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)}) \end{aligned}$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

$$\frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(1)}$$

Algoritmo Backpropagation



Universidade Federal
de Campina Grande

Algoritmo Backpropagation

- *Forward propagation* (inference):

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$J(\mathbf{y}) = \frac{1}{2}\|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2}\|\mathbf{e}\|^2$$

Algoritmo Backpropagation

- *Forward propagation* (inference):

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$J(\mathbf{y}) = \frac{1}{2}\|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2}\|\mathbf{e}\|^2$$

- *Backward propagation* (training):

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} (\mathbf{z}^{(2)})^T \quad \frac{\partial J}{\partial \mathbf{b}^{(3)}} = \delta^{(2)}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(1)} \mathbf{x}^T \quad \frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(1)}$$

Algoritmo Backpropagation

- *Forward propagation* (inference):

$$\mathbf{a}^{(2)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(2)}$$

$$\mathbf{z}^{(2)} = f(\mathbf{a}^{(2)})$$

$$\mathbf{a}^{(3)} = \mathbf{W}^{(2)}\mathbf{z}^{(2)} + \mathbf{b}^{(3)}$$

$$\mathbf{y} = g(\mathbf{a}^{(3)})$$

$$J(\mathbf{y}) = \frac{1}{2}\|\mathbf{y} - \mathbf{d}\|^2 = \frac{1}{2}\|\mathbf{e}\|^2$$

- *Backward propagation* (training):

$$\delta^{(2)} = \mathbf{e} \odot g'(\mathbf{a}^{(3)})$$

$$\delta^{(1)} = (\mathbf{W}^{(2)})^T \delta^{(2)} \odot f'(\mathbf{a}^{(2)})$$

$$\frac{\partial J}{\partial \mathbf{W}^{(2)}} = \delta^{(2)} (\mathbf{z}^{(2)})^T \quad \frac{\partial J}{\partial \mathbf{b}^{(3)}} = \delta^{(2)}$$

$$\frac{\partial J}{\partial \mathbf{W}^{(1)}} = \delta^{(1)} \mathbf{x}^T \quad \frac{\partial J}{\partial \mathbf{b}^{(2)}} = \delta^{(1)}$$

μ : taxa de aprendizagem.
(learning rate).

$$\begin{aligned} \mathbf{W}^{(2)} &= \mathbf{W}^{(2)} - \mu \frac{\partial J}{\partial \mathbf{W}^{(2)}} & \mathbf{b}^{(3)} &= \mathbf{b}^{(3)} - \mu \frac{\partial J}{\partial \mathbf{b}^{(3)}} \\ \mathbf{W}^{(1)} &= \mathbf{W}^{(1)} - \mu \frac{\partial J}{\partial \mathbf{W}^{(1)}} & \mathbf{b}^{(2)} &= \mathbf{b}^{(2)} - \mu \frac{\partial J}{\partial \mathbf{b}^{(2)}} \end{aligned}$$

Algoritmo Backpropagation

- *Forward propagation* (inference): considerando uma MLP com N camadas.
- Para a camada de entrada (*input layer*):

$$\mathbf{z}^{(1)} = \mathbf{x}$$

Algoritmo Backpropagation

- *Forward propagation* (inference): considerando uma MLP com N camadas.

- Para a camada de entrada (*input layer*):

$$\mathbf{z}^{(1)} = \mathbf{x}$$

- Para as camadas $n = 1$ até $N - 1$ (*input layer + hidden layers*):

$$\mathbf{a}^{(n+1)} = \mathbf{W}^{(n)} \mathbf{z}^{(n)} + \mathbf{b}^{(n+1)}$$

$$\mathbf{z}^{(n+1)} = f(\mathbf{a}^{(n+1)})$$

Algoritmo Backpropagation

- *Forward propagation* (inference): considerando uma MLP com N camadas.

- Para a camada de entrada (*input layer*):

$$\mathbf{z}^{(1)} = \mathbf{x}$$

- Para as camadas $n = 1$ até $N - 1$ (*input layer + hidden layers*):

$$\mathbf{a}^{(n+1)} = \mathbf{W}^{(n)} \mathbf{z}^{(n)} + \mathbf{b}^{(n+1)}$$

$$\mathbf{z}^{(n+1)} = f(\mathbf{a}^{(n+1)})$$

- Para a camada de saída (*output layer*):

$$\mathbf{a}^{(N)} = \mathbf{W}^{(N-1)} \mathbf{z}^{(N-1)} + \mathbf{b}^{(N)}$$

$$\mathbf{y} = g(\mathbf{a}^{(N)})$$



Universidade Federal
de Campina Grande

Algoritmo Backpropagation

- *Backpropagation* (training): considerando uma MLP com N camadas.

Algoritmo Backpropagation

- *Backpropagation* (training): considerando uma MLP com N camadas.
- Para a camada de saída N (*output layer*):

$$\delta^{(N-1)} = \mathbf{e} \odot g'(\mathbf{a}^{(N)}) \quad \frac{\partial J}{\partial \mathbf{W}^{(N-1)}} = \delta^{(N-1)} (\mathbf{z}^{(N-1)})^T \quad \frac{\partial J}{\partial \mathbf{b}^{(N)}} = \delta^{(N-1)}$$

Algoritmo Backpropagation

- *Backpropagation* (training): considerando uma MLP com N camadas.
- Para a camada de saída N (*output layer*):

$$\delta^{(N-1)} = \mathbf{e} \odot g'(\mathbf{a}^{(N)}) \quad \frac{\partial J}{\partial \mathbf{W}^{(N-1)}} = \delta^{(N-1)} (\mathbf{z}^{(N-1)})^T \quad \frac{\partial J}{\partial \mathbf{b}^{(N)}} = \delta^{(N-1)}$$

- Para as camadas $n = N - 1$ até 2 (*hidden layers + input layer*):

$$\delta^{(n-1)} = (\mathbf{W}^{(n)})^T \delta^{(n)} \odot f'(\mathbf{a}^{(n)}) \quad \text{Quando } n = 2, \text{ temos } \mathbf{z}^{(1)} = \mathbf{x}.$$

$$\frac{\partial J}{\partial \mathbf{W}^{(n-1)}} = \delta^{(n-1)} (\mathbf{z}^{(n-1)})^T$$

$$\frac{\partial J}{\partial \mathbf{b}^{(n)}} = \delta^{(n-1)}$$